

Data Engineering: Pipeline & Preparation



Eka Surya Aditya

AI/Machine Learning Engineer

Pendidikan: M.T (Master at Data Science/AI) - 2022

S.T (Teknik Informatika ITB) - 2020

Pengalaman:

Senior AI/ML Engineer at Telkomsel Ecosystem Digital (2025-Now)

Data Scientist at SVI (2023-2025)

AI Engineer at Pusat AI ITB (2020-2022)

OBJECTIVE & OUTLINE



Data Engineering: Pipeline & Preparation

Objektif: Memahami berbagai tipe data dan mengetahui sumber pengambilan data yang tepat

Outline:

1. Data Source for AI Systems
2. Data Cleaning and Preparation
3. Data Transformation
4. Data Pipeline

ReWork.

Data Source for AI Systems

Sumber data

Internal sources

Spreadsheets (Excel, CSV, JSON, etc.)

Databases: can be queried via SQL, etc.

Text documents

Multimedia documents (audio, video)

External sources

Open data repositories

Public domain web pages

Sumber data daring

- Portal Satu Data Indonesia (<https://data.go.id>)
- Portal Data Jakarta (<https://data.jakarta.go.id>)
- Hugging Face (<https://huggingface.co/datasets>)
- Badan Pusat Statistik (<https://www.bps.go.id>)
- Badan Informasi Geospasial (<https://tanahair.indonesia.go.id/>)
- UCI Machine Learning repository (<https://archive.ics.uci.edu/ml/index.php>)
- Kaggle (<https://www.kaggle.com/datasets>)
- World Bank Open Data (<https://data.worldbank.org>)
- UNICEF Data (<https://data.unicef.org>)
- WHO Open Data (<https://www.who.int/data>)
- IBM Data Asset eXchange (<https://developer.ibm.com/exchanges/data/>)
- DBPedia (<https://www.dbpedia.org/resources/>)
- Wikidata (<https://www.wikidata.org/>) .


Susunan data

Butir data (*datum*): satuan terkecil data; satu nilai untuk satu variable tertentu

Data: kumpulan butir data yang membawa satu kesatuan makna (mendeskripsikan satu objek) tertentu.

Himpunan data (*dataset*): kumpulan data.

Metadata: data yang menjelaskan data yang lain.



"make":

- tipe: string,
- deskripsi: nama pabrik merek kendaraan

Tipe data berdasarkan susunannya

	Data terstruktur (structured data)	Data tak terstruktur (unstructured data)
Sifat	• Model data terdefiniskan sebelumnya • Format butir data (biasanya) teks. • Antar butir data terbedakan dengan jelas. • Ekstraksi/kueri langsung cukup mudah.	• Model data tidak terdefiniskan sebelumnya • Format butir data (biasanya) teks, citra, suara, video, dan format lainnya. • Antar butir data tidak cukup jelas terbedakan karena ketidakteraturan dan ambiguitas. • Ekstraksi/kueri langsung cukup sulit.
Contoh	Data tabular, <i>time series</i>	Data teks dalam dokumen teks bebas, data audio, data video.

Tipe Butir Data

	Nominal/kategorikal	Ordinal	Interval	Rasio
Sifat himpunan asal	Diskret, tidak terurut	Diskret, terurut	Kontinu/numerik, terurut, perbedaan menunjukkan selisih	Kontinu/numerik, terurut, nilai menunjukkan rasio terhadap kuantitas satuan/unit di jenis yang sama
Contoh	Warna (merah, hijau, biru)	Nilai huruf mahasiswa (A, B, C, D, E)	Suhu dalam Celcius, tanggal dalam kalender tertentu	Panjang jalan
Representasi nilai tipikal	Modus	Modus, median	Modus, median, rerata aritmetis	Modus, median, rerata aritmetik, rerata geometrik, rerata harmonik
Operasi matematika	$=, \neq$	$=, \neq, <, >$	$=, \neq, <, >, +, -$	$=, \neq, <, >, +, -, \times, \div$

Contoh model data: Tabular


- Terdiri dari N buah rekord (*record*)
- Masing-masing record mengandung D buah atribut
- Record = baris, *data point*, instant, *example*, transaksi, tupel, entitas, objek, vector fitur.
- Atribut = kolom, *field*, dimensi, fitur.
- Atribut yang sama untuk setiap record biasanya diasumsikan memiliki tipe butir data yang sama.
- Struktur dapat bersifat ketat/strict (contoh: basis data relasional) atau longgar/loose (contoh: Excel *spreadsheet*).
- Tergantung keketaan strukturnya, bisa ada bahasa kueri formal untuk mengakses butir-butir data didalamnya (contoh: SQL).

symboling	normalized-losses	make
3 ?		alfa-romero
3 ?		alfa-romero
1 ?		alfa-romero
2	164	audi
2	164	audi

Pengambilan Data


- Pengambilan data secara manual.
- Pengambilan data melalui API
 - Contoh melalui API Kaggle
 - Contoh melalui API Portal Data Bandung
- Pengambilan data melalui *web scraping*
- Pengambilan data melalui akses langsung ke basis data relasional yang ada.

Pengambilan data secara manual



Mengambil data (secara manual) dari Kaggle

- Kita akan mengakses data dari "Goal Dataset – Top 5 European Leagues" dari Kaggle.
- Kunjungi Kaggle.com dan login (buat akun jika perlu)
- Lakukan pencarian "goal dataset top 5 European leagues"
- Klik "Goal Dataset – Top 5 European Leagues"



Data Explorer

383.68 KB

- Bundesliga-goalScorer(20-...
- LaLiga-goalScorer(20-21).csv
- Ligue_1-goalScorer(20-21).c...
- Serie_A-goalScorer(20-21)....
- epl-goalScorer(20-21).csv**

< epl-goalScorer(20-21).csv (73.58 KB)  


Detail Compact Column 10 of 19 columns ▾

#	id	player_name	# games	# time	#
		522 unique values			
0	65		1	1	0
0	647	Harry Kane	35	3097	23
1	1250	Mohamed Salah	37	3085	22
2	1228	Bruno Fernandes	37	3117	18
3	453	Son Heung-Min	37	3139	17
4	822	Patrick Bamford	38	3085	17

- Di halaman data explorer, pilih "epl-goalScorer (20-21).csv"
- Unduh data dengan mengklik tombol unduh di bagian kanan dan simpan di folder kerja Anda.

Pengambilan data melalui API

- Data dapat diambil melalui *application programming interface* (API).
 - API disediakan oleh beberapa layanan data seperti Kaggle.
 - API token/key (mungkin) diperlukan untuk mengakses data via API.
 - Proses pembuatan API token/key (jika perlu) diperinci di dokumentasi masing-masing layanan.




Mengambil data dengan API dari Kaggle (1)

- Nyalakan Jupyter Notebook di folder kerja Anda, lalu buka atau buat satu skrip baru (Python 3).
- Instal `kaggle` library (mis: dengan pip)

```
In [1]: !pip install kaggle
```


Mengambil data dengan API dari Kaggle (2)

- Login ke Kaggle, klik foto profil Anda (di kanan atas), kemudian klik 'Your Profile' untuk membuka halaman profil Anda.
- Pada halaman profil Anda, klik tab 'Account'. Geser ke bawah sedikit, dan Anda akan menemukan tombol 'Create New API Token'



Mengambil data dengan API dari Kaggle (3)

- Klik 'Create New API Token'. Jika tombol tidak berfungsi, klik 'Expire API Token' lebih dahulu.
 - Browser akan mengunduh file `kaggle.json` ke folder unduhan (Downloads) Anda.
- Kaggle API secara default mengasumsikan bahwa file `kaggle.json` tersebut berada di dalam folder:
`~/.kaggle/` (Linux/Mac) atau
`C:\Users\<Windows-username>\.kaggle\` (Windows)
 - Jika folder tersebut belum ada, buat dulu dengan perintah `mkdir` di shell/command line.
 - Pindahkan file `kaggle.json` ke folder tersebut (menggunakan File/Windows Explorer atau melalui perintah `mv` atau `move` di shell)

Mengambil data dengan API dari Kaggle (4)

- Kaggle API memiliki empat perintah
 - `kaggle competitions {list, files, download, submit, submissions, leaderboard}`
 - `kaggle datasets {list, files, download, create, version, init}`
 - `kaggle kernels {list, init, push, pull, output, status}`
 - `kaggle config {view, set, unset}`
- Dokumentasi Kaggle API dapat dilihat di <https://github.com/Kaggle/kaggle-api>
- Untuk keperluan modul ini, kita hanya menggunakan perintah `kaggle datasets`

Mengambil data dengan API dari Kaggle (5)

- Untuk melakukan pencarian dataset: `kaggle datasets list -s <keyword>`
 - Jika terjadi masalah gagal akses, dsb., bisa dicoba dengan membuat ulang API Token.
- Nama dataset berada di kolom ref pada tabel output pencarian. Misalnya kita ingin mengunduh "Goal Dataset – Top 5 European Leagues, maka nama dataset adalah

shreyanshkhanelwal/goal-dataset-top-5-european-leagues

In [2]: `!kaggle datasets list -s "goal leagues"`

ref ated	downloadCount	voteCount	usabilityRating	title	size	lastUpd
-----	-----	-----	-----	-----	-----	-----
slehkyi/extended-football-stats-for-european-leagues-xg -02 17:28:39	2733	94	1.0	Football Data: Expected Goals and Other Metrics	1MB	2020-08
secareanualin/football-events -25 01:19:19	19416	525	0.7647059	Football Events	21MB	2017-01
shreyanshkhanelwal/goal-dataset-top-5-european-leagues -23 21:20:09	25	6	0.5294118	Goal Dataset - Top 5 European Leagues	174KB	2021-05
chaibapat/fantasy-premier-league -16 18:56:26	1466	31	0.85294116	Fantasy Premier League - 2016/2017	476MB	2017-05
yamaerenay/most-popular-soccer-leagues -01 16:59:30	78	5	1.0	Most Popular Soccer Leagues	30KB	2020-08


Mengambil data dengan API dari Kaggle (6)

- Unduh dataset yang diinginkan dengan perintah `kaggle datasets download`

```
In [3]: !kaggle datasets download shreyanshkhandelwal/goal-dataset-top-5-european-leagues
```

- Dataset akan terunduh di folder aktif dalam bentuk file terkompresi zip.

Name



- .ipynb_checkpoints
- goal-dataset-top-5-european-leagues.zip
- kaggle-api-example.ipynb

- Selanjutnya, kita ekstraksi dataset tersebut dengan perintah `unzip`, dan dataset berupa berkas-berkas csv siap digunakan.

```
In [4]: !unzip goal-dataset-top-5-european-leagues.zip
```

```
Archive: goal-dataset-top-5-european-leagues.zip
  inflating: Bundesliga-goalScorer(20-21).csv
  inflating: LaLiga-goalScorer(20-21).csv
  inflating: Ligue_1-goalScorer(20-21).csv
  inflating: Serie_A-goalScorer(20-21).csv
  inflating: epl-goalScorer(20-21).csv
```

- Berkas csv dapat langsung dimuat ke Pandas DataFrame


Any question guys ~

Data Cleaning and Preparation

Pentingnya Data Preparation

- data perlu diformat sesuai dengan software yang digunakan
- data perlu disesuaikan dengan metode data sains yang digunakan
- data real-world cenderung 'kotor':
 - tidak komplit: kurangnya nilai attribute, kurangnya atribut tertentu/penting, hanya berisi data aggregate. misal: pekerjaan="" (tidak ada isian)
 - *noisy*: memiliki error atau outlier. misal: Gaji="-10", Usia="222"
- data real-world cenderung 'kotor':
 - tidak konsisten: memiliki perbedaan dalam kode dan nama. misal : Usia="32" Tgl Lahir="03/07/2000"; rating "1,2,3" -- > rating "A, B, C"
- kolom dan baris yang saling bertukar
- banyak variabel dalam satu kolom yang sama

Tahapan dan Tantangan Data Preparation



- **Memakan Waktu Lama**
- **Porsi Teknis yang Dominan**
- **Data yang Tersedia Tidak Akurat atau Jelas/Tidak Langsung Pakai**
- Data tidak Balance Saat Pengambilan Sampel
- Rentan akan Error

Tahapan Data Preparation: Pemilihan, Pembersihan & Validasi

1. Pilih/ Select Data

- Pertimbangkan pemilihan data
- Tentukan dataset yang akan digunakan
- Kumpulkan data tambahan yang sesuai (internal atau eksternal)
- Pertimbangkan penggunaan teknik pengambilan sampel
- Jelaskan mengapa data tertentu dimasukkan atau dikecualikan

2. Bersihkan/ Clean Data

- Perbaiki, hapus atau abaikan noise
- Putuskan bagaimana menangani nilai-nilai khusus dan maknanya
- Tingkat agregasi, nilai yang hilang (missing value), dll
- Bersihkan atau manipulasi outlier

3. Validasi Data

- Periksa/Nilai Kualitas Data
- Periksa/Nilai Tingkat Kecukupan Data

Parameter/Daftar Isi Dokumentasi Data Cleaning

Laporan dokumentasi data cleaning, setidaknya memiliki parameter berikut:

- Data Set Description
- Data Set yang digunakan
- Jenis noise yang terjadi pada data (diantaranya: Missing data, Data errors; Coding inconsistencies; Missing/ bad metadata
- Pendekatan yang dilakukan untuk menghilangkan noise tersebut
- Teknik mana yang digunakan sehingga berhasil untuk menghilangkan noise tersebut
- Apakah ada kasus atau atribut yang tak dapat diselamatkan
- Pastikan data yang dikecualikan karena kondisi noisenya


Parameter/Daftar Isi Dokumentasi Data Validation

Laporan dokumentasi data cleaning, setidaknya memiliki parameter berikut:

- Validasi data
 - Kebenaran, misal di Indonesia isian Gender yang diakui hanya 2 P/W; Agama hanya 6 (Islam, Protestan, Katholik, Hindu, Budha, Konghucu)
 - Kelengkapan, misal data propinsi seluruh Indonesia (34 prov), namun hanya sebagian yg ada
 - Konsistensi, misal penulisan STM atau SMK;
- Kecukupan data → Perlukan diulang berikan justifikasi (Resampling)

Tahapan Data Preparation: Versi Simple

Data Preparation Process




Any question guys ~

ReWork.

Data Transformation

Scaling: Normalisasi

- Nama Lain: Min-Max Scaling.
- Definisi: Teknik penskalaan di mana nilai-nilai digeser dan diubah skalanya sehingga nilainya berkisar antara 0 dan 1 (rentang $[0,1]$).



$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Di sini, X_{max} dan X_{min} masing-masing adalah nilai maksimum dan minimum dari fitur.

- Ketika nilai X adalah nilai minimum dalam kolom, pembilangnya adalah 0, dan karenanya X' adalah 0.
- Sebaliknya, ketika nilai X adalah nilai maksimum dalam kolom, pembilangnya sama dengan penyebutnya sehingga nilai X' adalah 1.
- Jika nilai X berada di antara nilai minimum dan maksimum, maka nilai X' berada di antara 0 dan 1.

Hands On

```
import pandas as pd
import numpy as np
```

import pandas
dan numpy

```
data = pd.read_csv("scalling.csv")
data
```

membaca data

	Age	Income
0	44	72000
1	27	48000
2	30	54000
3	38	61000
4	40	50000
5	35	58000
6	27	52000
7	48	79000
8	50	83000
9	37	67000

Output

```
means = data.mean(axis = 0)
```

menghitung mean

```
max_min = data.max(axis = 0) - data.min(axis = 0)
```

menghitung
max - min

```
train_scaled = (data - means) / max_min
```

menerapkan
transformasi ke
data

```
train_scaled
```

	Age	Income
0	0.278261	0.274286
1	-0.460870	-0.411429
2	-0.330435	-0.240000
3	0.017391	-0.040000
4	0.104348	-0.354286
5	-0.113043	-0.125714
6	-0.460870	-0.297143
7	0.452174	0.474286
8	0.539130	0.588571

Output

Encoding Data Kategorikal

Model AI hanya memahami angka, bukan teks. Kolom kategorikal seperti "Elektronik", "Fashion", "Makanan" harus diubah terlebih dahulu sebelum dapat diproses.

Masalah & Solusi

Masalah

Model AI tidak bisa membaca teks kategorikal secara langsung – kolom seperti "Elektronik" atau "Fashion" tidak memiliki makna numerik bagi mesin.

Solusi

Setiap kategori teks diubah menjadi representasi angka (encoding), sehingga model dapat memproses dan belajar dari data tersebut.

Contoh Transformasi

Kategori (Teks)	Hasil Encoding (Angka)
Elektronik	0
Fashion	1
Makanan	2



Setiap kategori kini terwakili dalam bentuk numerik tanpa kehilangan informasi aslinya.

Transformasi Text Data

Teks mentah mengandung variasi penulisan yang membingungkan model — huruf besar/kecil tidak konsisten, simbol tidak perlu, dan tanda baca berlebihan. Pembersihan teks adalah langkah krusial sebelum pemrosesan lebih lanjut.



Teknik Pembersihan Dasar

1 Lowercasing

Mengubah seluruh teks menjadi huruf kecil agar tidak ada duplikasi kata yang sebenarnya sama.

2 Hapus Karakter Tidak Diperlukan

Menghilangkan simbol, tanda baca khusus, dan karakter yang tidak memberi makna pada model.

Contoh Sebelum & Sesudah

Sebelum


"HALO, Dunia!!!"

Sesudah

"halo dunia"

Data Pipeline

Any question guys ~



Apa itu Pipeline Data?

Pipeline data mengubah proses manual baris demi baris menjadi **rangkaian otomatis** yang dapat dijalankan ulang kapan saja.

Alur Proses

Manfaat Utama

- Tidak perlu mengetik ulang setiap langkah secara manual
- Efisien dan hemat waktu di setiap iterasi
- Dapat direproduksi — jalankan ulang kapan saja dengan hasil konsisten

1

Dataset

2

Data Cleaning

3

Transformasi

4

Processed Dataset

Membangun Pipeline Langkah Demi Langkah

Setiap tahap pipeline direpresentasikan oleh sebuah **function** — modular, terpisah, dan mudah diuji.

1

Membaca Dataset

Function untuk memuat file CSV lokal ke dalam DataFrame menggunakan Pandas. Ini adalah *entry point* pipeline.

2

Data Cleaning

Function untuk menangani **missing values** dan **duplicates** — menjaga kualitas data sejak dini.

3

Transformasi Data


Function untuk **normalisasi** dan **encoding** — mempersiapkan data agar siap dianalisis atau dimodelkan.

4

Menyimpan Hasil

Function untuk mengeksport *processed dataset* ke file CSV baru sebagai output akhir pipeline.

Pipeline & Standar Industri ETL



Menghubungkan Praktik ke Terminologi Profesional

Pipeline yang telah kita bangun bukan hanya latihan teknis – ia mencerminkan standar industri yang dikenal sebagai **ETL**.

- Memahami istilah ETL membuka pintu ke percakapan teknis profesional di dunia data engineering dan data science.

Extract

Membaca dataset (Langkah 1)

Transform

Data cleaning dan transformasi (Langkah 2-3)

Load

Menyimpan hasil akhir (Langkah 4)

ReWork.

Thank You 🙌